

Université Jean Monnet

Academic Year 2024-2025

Machine Learning Fundamentals

Date: March 2025

Duration: 1.5 hours

Instructions to Students

1. This exam consists of **three (3)** tasks. You must submit your solutions as a file (.ipynb or .py) on Moodle.
2. Name your file as: [YOUR_FIRST_NAME]_[YOUR_LAST_NAME].[ipynb or py]
3. A CSV file with the dataset is available on Moodle.
4. Your code must be well-structured and **commented**.
5. You may use Jupyter Lab, VIM, Nano, or EMACS to write your code. To launch Jupyter Lab, use: `jupyter lab` in the command prompt.
6. The following websites are accessible for documentation:
 - Fast access:
 - <https://imbalanced-learn.org/>
 - <http://seaborn.pydata.org/>
 - Slow access:
 - <https://numpy.org/>
 - <https://scikit-learn.org/>
7. PDF documentation for the following libraries is available on Moodle (*download and unzip* the provided file):
 - Matplotlib

Université Jean Monnet

- Pandas
 - Numpy
 - Scikit-learn
 - Seaborn
8. Any generated table or figure must be accompanied by a brief explanation.
 9. No internet access is allowed. However, you may consult a double-sided paper reference.

Question 1

Describe the dataset using figures and tables. The data might exhibit class imbalance and contain outliers. You may use statistical tests as well. Comment on your findings within your code.

Note: If outliers are detected, you are not required to apply correction techniques.

Question 2

Apply the **Support Vector Machine (SVM)** method to classify your dataset. If class imbalance is present, apply one or more techniques to address it (e.g., SMOTE, random downsampling, ADASYN, etc.). Compare results with and without applying imbalance techniques.

You must use **cross-validation (grid search)** to select the best hyperparameters/kernel.

Note: Excessively large hyperparameter grids may lead to long computation times. Prioritize presenting and analyzing results rather than exhaustive model tuning.

Recommended kernel options: ['rbf', 'poly'].

Question 3

Plot a **2D projection** of the dataset using **PCA, t-SNE, or UMAP**. Create a scatter plot where points are colored according to predictions from your best-performing SVM model.

END OF EXAM

Année Académique 2024-2025

Machine Learning Fundamentals

Date : March 2025

Durée : 1.5 heures

Instructions aux étudiants

1. Cet examen contient **trois (3)** tâches. Vous devez soumettre vos solutions sous forme de fichier (.ipynb ou .py) sur Moodle.
2. Nommez votre fichier comme suit : [VOTRE_PRÉNOM]_[VOTRE_NOM]_[ipynb ou py]
3. Un fichier CSV avec les données est disponible sur Moodle.
4. Votre code doit être bien structuré et **commenté**.
5. Vous pouvez utiliser Jupyter Lab, VIM, Nano ou EMACS pour écrire votre code. Pour lancer Jupyter Lab, utilisez : `jupyter lab` dans l'invite de commande.
6. Les sites de documentation suivants sont accessibles :
 - Accès rapide :
 - <https://imbalanced-learn.org/>
 - <http://seaborn.pydata.org/>
 - Accès lent :
 - <https://numpy.org/>
 - <https://scikit-learn.org/>
7. La documentation en PDF des bibliothèques suivantes est disponible sur Moodle (*téléchargez et décompressez* le fichier fourni) :
 - Matplotlib

- Pandas
 - Numpy
 - Scikit-learn
 - Seaborn
8. Toute table ou figure générée doit être accompagnée d'une brève explication.
 9. L'accès à Internet n'est pas autorisé. Cependant, vous pouvez consulter une feuille A4 de notes recto-verso.

Question 1

Décrivez le jeu de données en utilisant des figures et des tableaux. Les données peuvent présenter un déséquilibre des classes et/ou contenir des valeurs aberrantes (outliers). Vous pouvez également utiliser des tests statistiques. Commentez vos observations dans votre code.

Remarque : Si des outliers sont détectés, il n'est pas nécessaire d'appliquer des techniques de correction.

Question 2

Appliquez la méthode **Support Vector Machine (SVM)** pour classer votre jeu de données. En cas de déséquilibre des classes, appliquez une ou plusieurs techniques pour y remédier (par exemple, SMOTE, échantillonnage aléatoire, ADASYN, etc.). Comparez les résultats avec et sans correction du déséquilibre.

Vous devez utiliser **la cross-validation (grid search)** pour sélectionner les meilleurs hyperparamètres/kernel.

Remarque : Un espace de recherche trop large peut entraîner des temps de calcul excessifs. Priorisez l'analyse des résultats plutôt qu'une optimisation exhaustive.

Kernels recommandés : `['rbf', 'poly']`.

Question 3

Tracez une **projection 2D** des données en utilisant **PCA**, **t-SNE** ou **UMAP**. Créez un nuage de points où les observations sont colorées selon les prédictions de votre meilleur modèle SVM.

FIN DE L'EXAMEN